

Dispositivo para monitorar a ingestão de água por meio de uma garrafa

Abstract—Nos últimos anos, houve o surgimento de dispositivos focados em monitorar a saúde das pessoas, como, por exemplo, smartwatches, anéis, roupas inteligentes, entre outros. Apesar de existirem vários dispositivos com diferentes focos, há poucos que se concentram no monitoramento da ingestão de água, sendo essa uma variável vital para a saúde humana. Nesse sentido, o presente trabalho apresenta o desenvolvimento de uma solução, que consiste em fixar um acelerômetro em uma garrafa. Dessa forma, a partir de um modelo com 95,4% de precisão nas simulações e 96,5% nos testes práticos, identifica-se a quantidade de goles e a duração de cada um deles. Após a identificação, os dados são enviados através de uma conexão Bluetooth para um aplicativo no celular, assim o usuário pode realizar o monitoramento do seu consumo de água ao longo do dia.

Index Terms—água, saúde, Arduino, acelerômetro, *machine learning*

I. INTRODUÇÃO

Ao longo dos últimos anos, houve o surgimento de diversas pesquisas na área de embarcados com o enfoque em propor soluções para ajudar o usuário a realizar um acompanhamento, ao longo do dia, de variáveis relacionadas a saúde. O artigo [1], apresenta uma pesquisa de soluções nessa área, fornecendo uma lista de doenças que já podem, de forma preliminar, ser detectadas através de dispositivos que monitoram sinais vitais do usuário, como batimento cardíaco, pressão arterial, nível de oxigenação, entre outras.

Além das que foram citadas anteriormente, um dos elementos mais importantes para a saúde humana é a água, visto que o corpo humano é composto por aproximadamente 70% dela. Conforme [3] ao longo do dia, em condições normais de dieta, clima e exercício, o corpo elimina cerca de 500 ml de água pela urina, além disso, há uma outra parcela que é expelida através do suor. Desse modo, é fundamental que haja reposição do líquido que foi perdido para que danos à saúde, como dores de cabeça, confusão mental, ressecamento da pele e problemas nas funções renais e urinárias, sejam evitados. Sendo assim, é necessário controlar a quantidade de água ingerida ao longo do dia. De acordo com [3], a recomendação diária de água para homens é 3,000 ml e para mulheres, 2,200 ml.

Para que esse monitoramento seja simples e fácil, o presente projeto desenvolveu um dispositivo capaz de mensurar a quantidade de vezes que uma pessoa ingeriu água durante o dia, bem como a duração de cada gole. Com um sensor acelerômetro fixado em uma garrafa, foi desenvolvido um modelo que, a partir da leitura dos 3 eixos e do giroscópio é capaz de identificar os goles com 95,4% de precisão.

II. PROJETOS SEMELHANTES

Atualmente, no mercado, há algumas garrafas que realizam esse gerenciamento, como o levantamento feito por [2]. Para identificar a quantidade de água ingerida pela pessoa durante o dia, a maioria das aplicações utiliza uma célula de carga (sensor de peso) na base da garrafa. Dessa forma, a partir da sua variação, sabe-se o consumo de água ao longo do dia.

Além dos produtos comerciais, o seguinte artigo [4] apresenta uma proposta semelhante. Os autores desenvolveram o projeto utilizando um Arduino Nano BLE 33. A plataforma utilizada, possui Bluetooth e acelerômetro embutidos, o que simplifica a implementação na garrafa. O dataset utilizado no trabalho, contou com dados provenientes de 5 voluntários e, para realizar a classificação do movimento, eles utilizaram uma rede neural, variando a quantidade de neurônios entre 1 e 5, e obtiveram aproximadamente 20% e 95% de acurácia, respectivamente. Também realizaram a estimativa de consumo de energia, demonstrando que, como esperado, a rede com 5 neurônios consome mais.

O presente trabalho pretende ser uma alternativa a essas soluções, no sentido de oferecer maior versatilidade ao dispositivo em relação às soluções comerciais. Tendo em vista que, por ser utilizado um sensor acelerômetro, ele pode ser adicionado a qualquer garrafa ou copo, uma vez que o sensor de carga requer uma construção e calibração específicas para que consiga realizar a medição. Além disso, a massa da garrafa não pode sofrer grandes alterações ao longo do tempo. Como o acelerômetro vai classificar o movimento, estará imune a esse problema.

Em relação ao artigo [4], o presente trabalho propõe apresentar um modelo menos complexo para a classificação do movimento. Foram avaliados modelos de regressão (linear e logística) como alternativa a rede neural. Além disso, o custo do Arduino Nano BLE 33 é cerca de 7 vezes maior que o da versão Uno, desse modo, a solução proposta é mais econômica.

III. OBJETIVO

Desenvolver um dispositivo capaz de monitorar a ingestão de água, a partir de uma garrafa. Utilizando um sensor acelerômetro, um modelo classificador de movimento, conexão Bluetooth e um aplicativo para visualização dos dados.

IV. MÉTODOS

A primeira parte do desenvolvimento da solução, foi a construção de um *data logger*, com o objetivo de coletar dados para a entrada do modelo. Com os dados coletados, a segunda etapa consistiu no treino, análise e validação de diferentes tipos

de modelos para definir aquele com a melhor classificação. Por fim, foi realizada a construção e os testes da solução final.

A. Data logger

Na construção do *data logger*, foi utilizado como base o mesmo hardware da solução final, Arduino Uno e MPU-6050 (acelerômetro e giroscópio). Com a adição de um módulo micro SD para salvar os dados coletados, considerando a pouca memória ROM do Arduino e que nesta etapa não havia necessidade de utilizar o módulo Bluetooth.

O dispositivo foi projetado para realizar a aquisição de dados a cada 100 milissegundos e armazená-los em uma lista. A fim de que os dados não sejam escritos a todo momento no micro SD, evitando o consumo de processamento e energia, foi definido, a partir dos testes, que é possível armazenar 3 medições (300 milissegundos) na memória RAM, antes de salvar os dados. A partir dos testes, também foi identificado que o módulo costuma levar entre 30 e 50 milissegundos para escrever essa quantidade de dados, sendo assim, a frequência limite de amostragem é 20 Hz (50 milissegundos).

Além disso, foi adicionado um botão na lateral da garrafa (Fig. 1), para registrar cada gole realizado pelo voluntário. No momento de levar a garrafa em direção a boca, ele pressionava o botão, desse modo, o modelo é capaz de relacionar o valor do sensor naquele instante com a ação de ingerir água.



Fig. 1. A - Garrafa da esquerda, B: Garrafa da direita

B. Dataset

Foi construído um dataset com os dados de 4 voluntários (3 homens), que somados, totalizam cerca de 20 minutos de gravação, sendo aproximadamente 3 minutos em momentos de ingestão de água. Eles realizarão a ingestão de água em diferentes situações: subindo uma escada, caminhando,

sentado em uma cadeira ou parado em pé. Também houve variação do tempo de cada gole, em cada situação foi proposto ao menos um gole mais rápido e outro mais lento.

Além de ingerir água em diferentes situações, os voluntários realizaram ações sem goles: caminhando, segurando a garrafa na mão e subindo uma escada.

Além desses dados, também houve coleta em situações sem goles, como a garrafa parada sobre uma mesa, dentro de uma mochila, no carro e posicionada em diferentes sentidos. Essa gravação totalizou aproximadamente 47 minutos. Sendo assim, o dataset é composto por 68 minutos de gravação, dos quais 3 minutos, aproximadamente 4%, referem-se ao período de ingestão de água.

C. Analise dos dados

Antes do treinamento do modelo, foi realizada uma análise com o objetivo de identificar as variáveis mais correlacionadas com a ingestão de água. Na Fig. 2 nota-se que as variáveis mais correlacionadas ao gole (*sip*) são os três eixos do acelerômetro, de forma negativa, e levemente, de forma positiva, o eixo y do giroscópio. Isso acontece devido a construção do dispositivo, visto que o posicionamento do sensor foi definido para que o eixo X sempre estivesse apontado na direção da boca. Na Fig. 1, há uma etiqueta que aponta a posição correta para ingerir água. Dessa forma, se essa orientação for seguida, independentemente da garrafa que for utilizada, a medição será feita da mesma maneira.




Fig. 2. Matriz de correlação

D. Modelo

Para o treinamento do modelo, os dados foram divididos em três grupos diferentes: treino, validação e teste. A tabela I apresenta a distribuição dos dados em termos de duração e quantidade de voluntários. Tomou-se o cuidado de não utilizar o mesmo voluntário em mais de dois grupos, a fim de evitar vies por parte do modelo.

Os dados no treino foram utilizados para definir os coeficientes do modelo. Na validação, além de validar a performance obtida, ela foi utilizada para identificar o melhor

TABLE I
DISTRIBUIÇÃO DOS DADOS

	Treino	Validação	Teste
Duração total (minutos)	40,6 (60,7%)	22,9 (33,7%)	4,5 (6,6%)
Tempo de gole (minutos)	1,2 (41,4%)	1 (34,5%)	0,7 (24,1%)
Voluntários	1	1	2

threshold a ser empregado no pós processamento do modelo, a partir disso, filtrou-se o sinal da saída do modelo classificando-o em duas *labels*: gole e não gole. Os dados do testes, serviram para realizar a avaliação final da performance, considerando os coeficientes e *threshold* obtidos nas etapas anteriores.

Foram utilizados 6 modelos de regressão diferentes: linear, logístico, ridge, ridge com cross-validation(ridge cv), classificador ridge e estocástico com gradiente descendente(SGD). Para cada modelo, foram testadas 7 variações diferentes de entradas, considerando diferentes combinações entre os valores dos sensores.

O modelo escolhido foi o linear, por ser simples e apresentar um bom valor para o *recall*, como demonstrado na seção de resultados. Ele possui 3 parâmetros (1), após sua saída aplica-se uma *sigmoid* (2), para calcular a probabilidade de ser gole, em seguida, o *threshold* definido na etapa de validação é utilizado para filtrar o resultado, assim, quando seu valor for igual a um, trata-se de um movimento de gole.

$$y = acc_x \cdot a + giro_y \cdot b + c \quad (1)$$

$$gole = \begin{cases} 1, sigmoid(y) > 0.57 \\ 0, sigmoid(y) \leq 0.57 \end{cases} \quad (2)$$

Termos da equação: $a = -0.06297311$, $b = 0.02817046$, $c = 0.0635120170557861$, acc_x : acelerômetro eixo X, $giro_y$: giroscópio eixo Y.

E. Métricas

Para avaliar o melhor modelo,, foram utilizadas 6 métricas diferentes, alguma delas estão apresentadas na tabela II, sendo classificadas com a seguinte ordem de importância: *recall*, acurácia, sensibilidade (*specificity*), média dos erros absolutos(MAE) e raiz do erro quadrático médio. O *recall*, foi definido como o mais importante, tendo em vista que o objetivo da solução é classificar dois movimentos: gole e não gole. Desse modo, por meio do *recall*, buscou-se reduzir a quantidade de falsos positivos do modelo, focando em classificar corretamente as duas ações.

No modelo escolhido (1), o *recall* foi igual a 0.784, conforme a tabela II. Esse valor é considerado bom, visto que o modelo classificou o gole corretamente em aproximadamente 78% dos casos de teste.

F. Solução final

Para construir a versão final (Fig. 1) do dispositivo, foram utilizados: um Arduino Uno, um acelerômetro, um módulo Bluetooth e uma bateria 9V. A leitura dos sensores é realizada há uma frequência de 10 Hz, enquanto os dados coletados são enviados a cada 5 segundos para o celular na versão de testes e a cada 5 minutos na versão final. Nos testes realizados, o Arduino, devido às suas limitações de memória, conseguiu armazenar até 30 goles antes de enche-la.

Para executar o modelo, as equações (1) e (2) foram implementadas no código C do Arduino Uno. Como são equações simples, não houve impacto na performance do Arduino. Para identificar a duração do gole, armazena-se o tempo em que a saída do modelo foi igual a 1. O celular recebe via Bluetooth a quantidade de goles, a duração de cada um deles, a média dos valores e apresenta todos os resultados, conforme demonstrado na Fig. 3. Uma vez que esses dados são enviados, a memória do Arduino é limpa e o celular se torna o responsável por armazená-los para análises futuras.



Fig. 3. Aplicativo no celular recebendo os dados do Arduino.

V. RESULTADOS

A. Resultados no conjunto de teste

Na tabela II, estão apresentados os resultados dos cinco melhores modelos no conjunto de testes. Ao todo, foram testadas 42 variações, as quais estão ordenadas com base no *recall* e na acurácia. Apesar de o modelo SGD, utilizando o eixo x do acelerômetro(Acc) e o y do giroscópio (Giro) ter apresentado a melhor performance, ele não foi o escolhido,

visto que ela é semelhante à de outros modelos mais simples. Nesse sentido, foi escolhido o modelo linear com os mesmos sensores, devido à sua implementação utilizar apenas 3 parâmetros (1), favorecendo o consumo de memória e a performance do Arduino Uno. Em (1) estão apresentados os parâmetros do modelo, quando seu valor é maior ou igual a 0.57 (*threshold*) a saída é classificada como gole (2).

TABLE II
RESULTADO DOS MODELOS NO CONJUNTO DE TESTE

Modelo	Sensores	Recall	Acurácia	MAE	RMSE
SGD	Acc X Giro Y	78,5%	95,4%	4,6%	21,4%
Ridge cv	Acc X Giro Y	78,4%	95,4%	4,6%	21,4%
Linear	Acc X Giro Y	78,4%	95,4%	4,6%	21,5%
Ridge	Acc X Giro Y	78,2%	95,4%	4,5%	21,3%
SGD	Acc X Giro X e Y	77,9%	95,8%	4,1%	20,3%

B. Teste com a versão final do dispositivo

Conforme apresentado na tabela III, a performance do modelo está coerente, e superior em média 15% para o *recall* e 4% na acurácia, em relação ao que foi observado na etapa de testes, para ambas as garrafas.

A garrafa A foi utilizada durante a coleta de dados, enquanto a B somente na fase testes, mesmo assim, obtiveram desempenho semelhante. Demonstrando que o dispositivo e o modelo desenvolvido são independentes do tipo de garrafa utilizada. Sendo assim, a utilização do acelerômetro se apresenta como uma alternativa à utilização de sensores de massa [2](artigo que apresenta solução com sensor de massa).

TABLE III
TESTES REALIZADO COM A VERSÃO FINAL DO DISPOSITIVO

Garrafa	Recall	Acurácia	MAE	RMSE
A	88,7%	95,7%	4,2%	20,7%
B	91,9%	97,3%	2,9%	17,2%
Média	90,3%	96,5%	3,6%	19%

C. Comparação com projeto semelhante

O artigo [4] apresenta um dispositivo similar ao proposto neste artigo. Em ambos, foi utilizado o acelerômetro como sensor para identificar o gole, porém, em [4] ao invés da versão Uno, foi utilizado um Arduino versão BLE e um modelo de regressão linear. Eles obtiveram uma acurácia de 94,8% em uma rede com 5 neurônios, um resultado similar aos 95,4% nos testes realizados com o modelo (tabela II) e 96% nos testes práticos (tabela III), obtidos com a regressão linear 1.

Contudo, para o *recall*, a rede neural do artigo [4] atingiu aproximadamente 94%, sendo assim, superior aos 78% da regressão linear no conjunto de testes(tabela II), mas similar aos 90% (tabela III) obtidos durante os testes práticos.

Apesar dessa leve melhora no *recall*, é mais interessante utilizar um modelo linear, como o proposto em 1. Tendo em vista que, dessa forma, é possível utilizar um hardware mais simples e barato que o Arduino Uno ou BLE, para realizar o processamento do modelo e a conexão com o celular

VI. CONCLUSÃO

A solução apresentada conseguiu classificar com cerca de 96,5% (tabela III) de precisão quando uma pessoa está ingerindo água. Além disso, a modelo utilizado foi uma regressão linear, dessa forma, a implementação da solução pode ocorrer em hardwares com baixa capacidade computacional, como é o caso do Arduino Uno.

Comparando com projetos semelhantes, a solução proposta se mostrou como uma alternativa a utilização de redes neurais e sensores de massa. Ademais, apresentou desempenho semelhante em diferentes garrafas, dessa forma, demonstrou robustez em relação a alterações no sistema.

Em contrapartida, ressalva-se que são necessários mais testes e a coleta de dados para treino, com mais *labels* de goles, para garantir que o modelo está preparado para classificar de forma correta nas mais diversas situações. Em conclusão, os sensor acelerômetro, assim como o modelo de regressão, mostraram-se eficazes para identificar quando uma pessoa está ingerindo água através de uma garrafa.

REFERENCES

- [1] Chioma Anikwe et al. "Mobile and Wearable Sensors for Data-driven Health Monitoring System: State-of-the-Art and Future Prospect". In: *Expert Systems with Applications* 202 (May 2022), p. 117362. DOI: 10.1016/j.eswa.2022.117362.
- [2] Good gear. *5 Smart Water Bottles Better Than The Stanley Cup*. 2025. URL: <https://www.goodgear.com/smart-water-bottles/> (visited on 09/14/2025).
- [3] Arend-Jan Meinders and Arend E Meinders. "How much water do we really need to drink?" In: *Ned Tijdschr Geneeskde*. (2010).
- [4] Avirup Roy et al. "An On-Device Learning System for Estimating Liquid Consumption from Consumer-Grade Water Bottles and Its Evaluation". In: *Sensors* 22.7 (2022). ISSN: 1424-8220. DOI: 10.3390/s22072514. URL: <https://www.mdpi.com/1424-8220/22/7/2514>.